

Wahrscheinlichkeit, Bedingung und Unabhängigkeit

Q3.1 · GK + LK

Bei $P(A|B)$ ist B bereits bekannt. Im Nenner stehen deshalb nur die Fälle aus B. Eine Vierfeldertafel oder absolute Anzahlen helfen, die Gruppen sichtbar zu machen. Unabhängigkeit bedeutet, dass diese zusätzliche Information die Wahrscheinlichkeit von A nicht verändert.

Bedingte Wahrscheinlichkeit

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

B ist bereits bekannt und bildet die neue Vergleichsgruppe.

Voraussetzung: $P(B) > 0$. Bedingungsrichtung nicht vertauschen.

Unabhängigkeit

$$P(A \cap B) = P(A)P(B)$$

Zusätzliche Information über B ändert die Wahrscheinlichkeit von A nicht.

Voraussetzung: Unabhängig bedeutet nicht unvereinbar.

Vereinigung und Bayes

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Bei „oder“ die Schnittmenge nicht doppelt zählen. Bayes berücksichtigt die Basisrate beim Umkehren der Bedingung.

Voraussetzung: Alle auftretenden bedingten Wahrscheinlichkeiten müssen definiert sein.

Zufallsgrößen, Binomial- und Normalverteilung

Q3.2 · GK + LK

Ein Balken der Binomialverteilung gehört zu einer ganzen Trefferzahl. Seine Höhe ist deren Wahrscheinlichkeit. Der Erwartungswert beschreibt die langfristige Mitte, nicht ein garantiertes Ergebnis. Bei einer stetigen Verteilung entsprechen Wahrscheinlichkeiten Flächen, nicht einzelnen Kurvenhöhen.

Binomialverteilung

$$P(X=k)=C(n,k)p^k(1-p)^{n-k}$$

$$C(n,k)=\frac{n!}{k!(n-k)!}$$

Zähle die Anordnungen mit k Treffern und multipliziere mit der Wahrscheinlichkeit einer Anordnung.

Voraussetzung: n unabhängige Versuche, zwei Ausgänge, konstantes p ; k ganzzahlig zwischen 0 und n .

Mitte, Streuung, Gegenereignis

$$\mu=np$$

$$\sigma=\sqrt{np(1-p)}$$

$$P(X\geq 1)=1-(1-p)^n$$

Der Erwartungswert ist keine garantierte Trefferzahl. Mindestens ein Treffer lässt sich über keinen Treffer berechnen.

Voraussetzung: X ist binomialverteilt; Modellannahmen prüfen.

Zufallsgrößen, Binomial- und Normalverteilung · Fortsetzung**Normalverteilung · LK**

$$P(a \leq X \leq b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$$

Wahrscheinlichkeiten sind Flächen unter der Dichte. Φ ist die Verteilungsfunktion der Standardnormalverteilung.

Voraussetzung: $X \sim N(\mu; \sigma^2)$, $\sigma > 0$. Ein einzelner Wert hat Wahrscheinlichkeit 0.

Hypothesentests und Fehlentscheidungen

Q3.3 · LK

Der Ablehnungsbereich gehört zur Entscheidungsregel. Das Signifikanzniveau begrenzt das Risiko, eine wahre Nullhypothese zu verwerfen. Es ist nicht die Wahrscheinlichkeit, dass die Nullhypothese nach Beobachtung der Daten wahr ist.

Rechtsseitiger Test

$$H_0: p \leq p_0$$

$$H_1: p > p_0$$

Eine vermutete Erhöhung wird durch ungewöhnlich große Trefferzahlen geprüft.

Voraussetzung: Hypothesen und Niveau vor der Stichprobe festlegen.

Kritische Grenze

Verwerfen bei $X \geq k$

$$P_{p_0}(X \geq k) \leq \alpha$$

Wähle die kleinste passende ganzzahlige Grenze k für den rechtsseitigen Binomialtest.

Voraussetzung: $X \sim B(n, p)$. Unter $H_0: p \leq p_0$ ist das rechtsseitige Verwerfungsrisiko am Rand p_0 am größten.

Fehlerarten

1. Art: wahres H_0 verwerfen

2. Art: falsches H_0 nicht verwerfen

Nicht verwerfen ist kein Beweis für H_0 . α ist keine Wahrscheinlichkeit für die Wahrheit von H_0 nach Betrachtung der Daten.

Voraussetzung: Das Risiko 2. Art hängt vom tatsächlichen Alternativwert ab.

Prognose- und Konfidenzintervalle

Q3.4 · Wahlthema

Ein Prognoseintervall beschreibt mögliche neue Beobachtungen bei einem Modell. Ein Konfidenzintervall wird aus einer Stichprobe konstruiert und zielt auf einen festen unbekannten Parameter. Größere Stichproben machen es typischerweise enger, beseitigen aber keine systematische Verzerrung.

Anteil und Standardfehler

$$\hat{p} = \frac{X}{n}$$

$$SE \approx \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Die Quote ist eine Punktschätzung; der Standardfehler beschreibt ihre zufällige Unsicherheit näherungsweise.

Voraussetzung: Passend erhobene, unabhängige Stichprobe; $n > 0$. Erhebungsverzerrungen bleiben möglich.

Näherungsweise 95%-Intervall

$$\hat{p} \pm 1,96 \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Beim Wald-Intervall beziehen sich 95 % auf das Überdeckungsverfahren über wiederholte Stichproben.

Voraussetzung: Nur für hinreichend große Stichproben und Abstand zu 0 und 1 brauchbar; bei 0 oder n Treffern ungeeignet.

Prognose- und Konfidenzintervalle · Fortsetzung**Prognose für Trefferzahlen**

$$\mu = np$$

$$\sigma = \sqrt{np(1-p)}$$

Bereich näherungsweise $\mu \pm 1,96\sigma$

Ein Prognoseintervall grenzt neue Beobachtungen bei bekanntem p ein, nicht einen unbekannten Parameter.

Voraussetzung: Normalapproximation nur unter geeigneten Bedingungen; ganzzahlige Grenzen und ggf. Stetigkeitskorrektur beachten.

Daten beurteilen und Verteilungen vergleichen

Q3.5 · Wahlthema

Prüfe bei einem Diagramm zuerst Achsen, Einheiten und Skalierung. Frage danach, welche Personen oder Fälle überhaupt erhoben wurden. Ein sichtbarer Zusammenhang kann durch weitere Einflüsse entstehen und beweist für sich allein keine Ursache.

Mittelwert und Median

$$\bar{x} = \frac{x_1 + \dots + x_n}{n}$$

Der Median ist die Mitte der sortierten Daten. Er reagiert weniger stark auf einzelne extreme Werte.

Voraussetzung: $n > 0$; bei geradem n die beiden mittleren Werte für den Median mitteln.

Deskriptive Streuung

$$s^2 = \left(\frac{1}{n}\right) \cdot \sum (x_i - \bar{x})^2$$

$$s = \sqrt{s^2}$$

Varianz: mittlerer quadrierter Abstand. Standardabweichung: wieder die ursprüngliche Einheit.

Voraussetzung: Hier Beschreibung vorhandener Daten. Für eine unverzerrte Populationsvarianz-Schätzung durch $n-1$ teilen.

Daten beurteilen und Verteilungen vergleichen · Fortsetzung**Poissonverteilung · LK**

$$P(X=k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

Modell für Ereigniszahlen in einem festen Zeitfenster unter passenden Annahmen wie konstanter mittlerer Rate und unabhängigen Ereignissen.

Voraussetzung: $\lambda > 0$; $k = 0, 1, 2, \dots$; Modellannahmen prüfen.